

PACER-M4：从结合检索到功能动态复核

整体算法、数据链、基准评估与 SOTA 主张边界

PACER-M4：按科学问题递进的证据级联，而非分数相加



硬边界：前三级回答‘值得进一步验证吗’；只有功能实验才能最终确认 PAM

核心结论：项目已经形成可运行、可审计的多阶段算法链；CGDA 在严格未见靶点检索中取得显著但有限的增益，四上下文 PACER-FKG 得到初步 hard-negative 特异性证据。当前尚不能宣称端到端 PAM 预测 SOTA，也不能把 5 个候选称为已确认 PAM。

1. 科学问题与算法主线

科学问题不是“哪个分子与 M4 别构口袋结合最强”，而是：在排除明显不相容分子后，如何判断候选物是否会在 ACh 存在时产生可重复、具有功能方向性的受体协同变化，并同时避免把无功能别构配体或内在激动剂误判为 PAM。

PACER-M4：按科学问题递进的证据级联，而非分数相加



硬边界：前三级回答‘值得进一步验证吗’；只有功能实验才能最终确认 PAM

四个模块回答不同问题，不能用一个随意权重合成：CGDA 回答结合检索；静态门控回答姿势合理性；四上下文回答条件效应与交互效应；PACER-FKG 回答这些动态变化能否跨 replica 重复。最终输出是证据卡与拒绝理由，而不是未经校准的“PAM 概率”。

2. 数据链与整体评价原则

五种数据协议不能折算成一个总 AUC

通用结合	LIT-PCBA 15 靶 / 2,807,612 对	ROC, PR, BEDROC, EF
外部 GPCR	DUD-E 5 GPCR / 91,311 分子	跨域压力测试
M4 功能标签	529 分子 + 5 个外部来源	PAM/非活性与效力
静态结构	430 potency + 454 docking	LOSO Spearman / MAE
四上下文动态	3 化合物 × 4 context × 3 replica	方向一致性 pilot


整体评价采用 ‘证据向量 + 固定预算级联’ ， 禁止跨数据集拼接指标

为什么不能给一个总 AUC：LIT-PCBA 评价跨靶点结合检索；M4 文献集评价功能标签或效力；四上下文 MD 目前只有 3 个化合物。样本宇宙、终点和统计单位不同。把它们标准化后相加会掩盖样本量、标签含义与泄漏风险。因而本报告给出一组整体证据向量，并在样本真正一致的子任务内做公平比较。

3. DrugCLIP 主线：CGDA，而不是只看 family-aug

CGDA (Context-Gated DrugCLIP Adapter) 冻结 DrugCLIP 编码器，用靶点口袋与共晶参考配体构造上下文，门控选择两个 rank-2 低秩残差专家。训练使用靶点内 active/decoy、跨靶点检索、困难负样本排序和表示保持损失；留出靶点的标签不进入训练。

Full LIT-PCBA 15-target LOTO: CGDA 的有效增益集中在 ROC 与早期排序




Full LIT-PCBA 15T	ROC-AUC	PR-AUC	BEDROC80.5	EF1%
Pocket DrugCLIP	0.5672	0.02379	0.06109	5.36
Reference retrieval	0.5693	0.02594	0.07103	6.06
CGDA hard-rank ensemble	0.5788	0.02627	0.07378	6.31

相对 reference retrieval, target-bootstrap 的 ROC 增益 +0.00954 (95% CI +0.00134 至 +0.01840) , BEDROC 增益 +0.00274 (+0.00045 至 +0.00504) 。这是严格可主张的结果；PR 与多数 EF 截断点不稳定。family-aug 的 13T ROC 0.641 是另一个协议下的域适配结果，不能与 Full LIT-PCBA 直接比较，也不能替代 CGDA。

4. 外部迁移与 M4 专化：有效，但并未解决效力

外部 DUD-E 5-GPCR: CGDA 稳定优于 reference, 但未超过 pocket DrugCLIP




在冻结后的 DUD-E 5-GPCR 外部压力测试中，CGDA 相对 reference retrieval 的 ROC、PR 和 BEDROC 均有正向 target-bootstrap 区间；但原始 pocket DrugCLIP 的 ROC/BEDROC 更高。因此可声称 “CGDA 改善 reference-assisted retrieval 的跨 GPCR 迁移”，不能声称 “CGDA 普遍优于 DrugCLIP”。

M4 外部来源	n (正/负)	Official DrugCLIP	GPCR-triplet	结论
Acadia 功能阈值	45 (43/2)	0.837	0.930	数值改善；差值 CI 跨零，负样本太少
Monash PAM/Inactive	14 (11/3)	0.576	0.788	方向改善；差值 CI 跨零
Suven potency	45	$\rho=-0.066$	$\rho=-0.106$	不能排序效力
VU6025733 potency	18	$\rho=-0.643$	$\rho=-0.637$	强系列/方向混杂，不是可用效力模型

因此 triplet 的真正价值是改善部分 M4 功能分类与毒蕈碱亚型排序表征；它没有把静态 DrugCLIP 变成 PAM 效力预测器。

5. 为什么不能只报一个漂亮 AUC



同一 529 分子，DrugCLIP 冻结探针在 scaffold holdout 看似达到 0.856，但 source holdout 降至 0.400；2D ExtraTrees 从 0.919 降至 0.629。说明模型主要受化学系列和来源差异影响。零样本 pocket score 约 0.491，更直接表明 “结合相似度” 不能替代 PAM 功能。

M4 potency LOSO (12 series)	macro Spearman	worst series	解释
Vina only	0.043	-0.226	静态亲和打分几乎无效
2D LightGBM	0.199	-0.130	系列内结构信号仍占主导
Structure RF	0.170	-0.030	结构特征较稳但增益有限
2D + Structure LightGBM	0.208	-0.152	宏均值小幅提升，最差系列恶化

结论不是 “MD 一定更好” ，而是静态模型无法承担功能效力终点；动态模块必须用已知 PAM 与 hard negative 做独立机制复核。

6. 四上下文 PACER-DC / PACER-FKG

四个匹配体系：A=apo, P=ACh probe only, C=candidate without probe, CP=candidate+ACh。由同一冻结 C1-BS256 表征生成三种差分：



$$\Delta AGO = C - A$$

$$\Delta PAM = CP - P$$

$$\Delta INT = CP - P - C + A$$


同一受体、同一膜环境、匹配 seed 与 replica；比较方向，而非只比较变化幅度

差分	公式	生物学问题
ΔPAM	$CP - P$	在已有 ACh 条件下，加入候选物改变了什么
ΔAGO	$C - A$	候选物在无 ACh 时是否自行推动受体状态
ΔINT	$CP - P - C + A$	候选物与 ACh 的非加性交互变化

编码器并非 OneProt 最终头。当前冻结主线从预训练 Geom2Vec/ViSNet 的 C1 中间 message-passing state 读取原子 invariant 特征 (scalar 64 + vector norm 64)，按残基 backbone/sidechain 均值拼成 BS256。PACER-FKG 在预定义区域、共同核空间和匹配 replica 中比较差分方向。

最重要的统计纠偏：核距离的大小没有方向，且不同区域若使用不同核尺度就不能相减。当前主结果采用共同坐标系中的带符号方向余弦；时间块只作相关子样本，不能冒充独立生物学重复。


7. 四上下文结果：partial specificity support



对象	药理身份	主区域 ΔINT R1/R3 cosine	可解释结论
compound110	ago-PAM / allosteric agonist	+0.584	局部方向可重复；其他区域并不一致
LY2119620	已知 PAM	+0.634	多个机制区为正，支持已知 PAM 的方向模式
CM00734	实验 inactive hard negative	-0.327	7 个报告区域均为负，提供冻结 hard-negative 支持

这是目前最有价值的动态结论：区分力来自跨 replica 的方向一致性，而不是 ΔINT 幅度。CM00734 的幅度仍可达到 LY 的 0.53-0.80，单看 ‘变化有多大’ 会误判。由于只有 2 个功能分子和 1 个 hard negative，不能计算可信 AUC、阈值或效力回归，也不能宣称 SOTA classifier。


8. 整体算法的一系列指标



这张图不是让柱高彼此竞争，而是展示全流程每个科学终点已有多少证据。当前链条在“通用结合检索”上有大规模严格验证，在“M4 功能迁移”上有小样本外部提示，在“功能效力排序”上仍失败，在“四上下文动态”上只有三化合物机制闭环。

阶段	当前最强证据	当前缺口	比赛中应如何表述
结合检索	CGDA: 2.8M LIT-PCBA + 外部 5-GPCR	未全面胜过 pocket DrugCLIP/所有 SOTA	严格未见靶点增益
M4 专化	triplet: Acadia/Monash 数值改善	负样本少，效力不改善	外部压力测试，不称确认
静态结构	姿势、IFP、LOSO 结构特征	Vina 与效力弱相关	作为门控与解释，不作功能分数
动态功能	LY/CM 冻结 hard-negative 对照	n=3，无通用阈值	部分特异性机制支持

9. 候选物交接：有可审计 shortlist，没有已确认 PAM



候选	旧 rank	family-aug rank	DrugCLIP p	famaug score	max Tanimoto
PACER0040	15	6	0.821	0.543	0.717
PACER0154	46	7	0.779	0.542	0.591
PACER0125	45	8	0.779	0.531	0.580
PACER0057	11	14	0.831	0.520	0.726
PACER0053	37	23	0.792	0.500	0.612

固定规则为旧 PACER-200 rank≤50 且 family-aug rank≤25。5 个候选均通过 PAINS/drug-like 检查，但属于相近 fragment chemotype；尚未完成各自的四上下文 MD，更没有湿实验。因此这里只能称为优先验证候选。

10. 应与哪些算法对标，以及怎样证明 SOTA

任务	必须 baseline	同协议指标	当前状态
大规模结合检索	DrugCLIP pocket/reference; ECFP; random	ROC, PR, BEDROC, EF0.5/1/2/5	CGDA 已完成同协议 LOTO
结构重打分	Vina; GNINA; RTMScore; EquiScore; DeepRLI	同一 pose/同一靶点/同一候选库	Vina 已跑; 其余只能列 published reference, 不能宣称胜出
M4 功能分类	ECFP/RF; DrugCLIP frozen; GPCR-triplet	source/series holdout + 外部来源	已完成, 但样本不均衡且外部负样本少
M4 效力排序	2D RF/LGBM; static structure fusion	LOSO Spearman, MAE, worst-series	整体仍弱; 不主张解决
MD 表征	PCA/tICA/VAMP; OneProt; Geom2Vec final	同轨迹、同窗口、replica holdout	C1-BS256 方向稳定性更好; 仅特定体系
PAM 功能动态	state-only; 无图; 单差分; 置乱图	预注册区域、方向、hard negative	三化合物 pilot, 尚无领域标准 benchmark

可接受的 SOTA 证明必须同时满足：同一公开数据、同一输入信息、同一切分、同一指标、预先冻结模型选择、对目标或样本单位 bootstrap，并优于最强可运行 baseline。当前项目只有局部的 “best among tested baselines” ；不具备 “端到端 PAM SOTA” 证据。更有力量的竞赛表述是：我们识别了静态结合与功能 PAM 之间的评估缺口，并给出一个带 hard-negative 和拒绝机制的动态复核框架。

11. 最终结论与提交前优先级

优先级	必须完成	理由
P0	冻结 CGDA、family-aug、PACER-FKG 的用途边界，统一候选 ID 与证据卡	避免把不同协议和不同分子库拼接
P0	对 5 个候选至少选择 1-2 个完成四上下文 MD；同时保留已知 PAM 与 inactive 对照	把候选链真正接到动态模块
P1	补 GNINA/RTMScore 中至少一个同 pose 重打分 baseline，或明确 NOT RUN	回应 ‘docking 太古早’ 的质疑
P1	扩充跨 chemotype PAM 与 hard negative，预注册 ΔINT 主区域	把 n=3 pilot 推向可估计性能
P2	湿实验验证 ACh 条件下曲线位移、Emax 与 intrinsic agonism	唯一能确认 PAM 身份的终点

一句话定位

PACER-M4 是一个把通用结合检索、静态结构门控和 ACh 条件化四上下文动态复核连接起来的证据级联系统；其创新点是显式区分 “可能结合” 与 “可能产生功能性协同”，并以冻结 hard negative 和拒绝机制约束结论。

主要参考

DrugCLIP, NeurIPS 2023, https://papers.nips.cc/paper_files/paper/2023/hash/8bd31288ad8e9a31d519fdeede7ee47d-Abstract-Conference.html
LIT-PCBA, Jcim 2020, <https://doi.org/10.1021/acs.jcim.0c00155>
GNINA 1.3, J. Cheminformatics 2025, <https://doi.org/10.1186/s13321-025-00973-x>
RTMScore, J. Med. Chem. 2022, <https://doi.org/10.1021/acs.jmedchem.2c00991>
EquiScore, Nature Machine Intelligence 2024, <https://doi.org/10.1038/s42256-024-00849-z>
VAMPnets, Nature Communications 2018, <https://doi.org/10.1038/s41467-017-02388-1>
Geom2Vec, arXiv:2409.19838, <https://arxiv.org/abs/2409.19838>